

UniGen-LingXi: 资源高效、编辑优先的统一框架 实现九合一多模态生成与编辑

Haiying Sha 854197093@qq.com¹

¹ 独立研究者

* 通讯作者: Yan Zheng 1062746470@qq.com

Abstract

视频扩散模型的最新进展在生成和编辑方面展现了令人瞩目的能力。然而,现有框架大多是碎片化的,专精于单一任务(如文本生成视频或局部编辑),这限制了 workflow 效率并增加了部署开销。本文提出 UniGen-LingXi-5B, 一个资源高效、编辑优先的统一框架,将完整的九合一多模态生成与编辑套件整合到单一、未修改的架构中。基于 Kiwi-Edit 模型,我们的核心见解是将多样化任务——包括文本生成图像/视频、图像生成视频,以及各种参考引导的编辑/生成任务——重新表述为统一的条件视频生成问题。我们设计了一套可扩展的数据构建管线,能够自动将异构数据集转换为任务对齐的训练序列,并开发了一个优化的训练脚本,通过梯度检查点、RoPE 缓存和 8 位优化等内存高效技术,实现了在单张 A100 (80GB) 上的 81 帧视频训练。

尽管面临严重的算力和数据约束(约 2 万条样本和单 GPU),UniGen 成功学习了跨模态任务路由和条件控制,证明了所有九种任务均可在单一模型中功能性地实现。该模型在风格迁移、局部属性操作和运动保持的风格化方面展现出强大性能。我们透明地记录了当前在复杂参考引导的主体替换和细粒度文本生成图像方面的边界,凸显了数据受限条件下统一架构的内在权衡。本工作并非声称全面的 SOTA 性能,而是作为编辑优先统一的严格概念验证,并建立了清晰的规模化发展轨迹。我们公开发布模型权重和推理脚本,以促进社区驱动的研究,并邀请业界和学术界合作,利用更大规模的数据集和计算资源来扩展这一范式。

- ▷ GitHub <https://github.com/Lingxi-Qihang/UniGen-LingXi>
- ▷ HuggingFace <https://huggingface.co/shyai/UniGen-LingXi-5B>
- ▷ ModelScope <https://modelscope.cn/models/haohanxingcheng/UniGen-LingXi-5B>



Figure 1: UniGen-LingXi-5B 架构总览。




Figure 2: UniGen-LingXi-5B 在高保真图像生成方面的展示。

1 引言

随着视频和图像内容创作需求日益灵活和多样化,生成模型得到了快速发展。两大范式已然浮现:基于指令的编辑(例如,“把天空变成日落”)和参考引导的生成(例如,“让这张图动起来”)。虽然 Kiwi-Edit 等模型(1)通过结合多模态大语言模型(MLLM)和扩散 Transformer(DiT)在视频编辑方面表现出色,但其设计目标仅限于编辑现有视频。反之,纯生成任务(文本生成视频、文本生成图像、图像生成视频)通常由不同的模型分别处理,用户需要在不同管线之间来回切换。

本文提出 UniGen,一个统一框架,使单一的 Kiwi-Edit 模型无需任何架构修改即可执行全部九种任务。我们的核心思想是将每种任务重新解释为一个条件视频生成问题:给定一个源视频(从输入构建)和一个带有任务前缀的文本提示,模型学习生成目标视频。例如:

- 文本生成视频:源视频 = 全白帧。
- 文本生成图像:源视频 = 全白帧;目标是每帧都是同一张图像的静态视频。
- 图像生成视频:源视频 = 第一帧(输入图像)+ 后续白帧。
- 图像编辑:源视频 = 输入图像的静态视频;目标 = 编辑后图像的静态视频。
- 视频编辑:源视频 = 原始视频;目标 = 编辑后的视频。
- 参考引导的任务:上述任意任务在额外提供一张参考图像作为条件后,衍生出另外四种任务(Ref-IE、Ref-T2I、Ref-T2V、Ref-VE)。

尤为关键的是,我们在严格的资源约束下验证了这种统一性。我们的实验在单张 NVIDIA A100 GPU 上仅使用 2 万条训练样本完成——这一配置对于大多数学术实验室和独立研究者而言都是可及的。这与文本生成视频或专用编辑模型通常所需的大规模多 GPU 训练形成了鲜明对比。因此,我们的工作作为一个概念验证,证明了数据高效、编辑优先的范式可以成为通向统一多模态内容创作的实用路径,即便对于计算预算有限的研究者也是如此。

我们的核心贡献如下:

- 九合一资源高效框架:我们证明了一个单一的、未修改的模型能够支持全部九种任务,仅用 2 万条训练样本便取得了强劲性能。
- 可扩展的数据构建管线:一个自动化流程,将异构的公共数据集转换为任务对齐的训练序列。
- 内存高效的训练方案:梯度检查点、RoPE 缓存和 8 位 Adam 等技术使得在单张 A100 上训练 81 帧、720p 视频成为可能。
- 透明的边界分析:我们识别了统一性能有所下降的具体子任务,为未来超越当前资源限制的规模化提供了清晰的路线图。
- 开源发布:我们公开了推理代码和模型权重,以促进社区的采用和规模化扩展。

2 相关工作

基于指令的视频编辑随着 Ditto-1M(2)、OpenVE-3M(3) 和 ReCo(4) 等数据集的推出而快速发展。InsViE(5) 和 OpenVE-Edit(6) 等模型通过微调视频扩散模型以遵循自然语言指令。Kiwi-Edit(1)通过引入冻结的 MLLM(Qwen2.5-VL-3B)和 DiT 骨干网络(Wan2.2-TI2V-5B),并采用多阶段训练课程,进一步提升了性能。

视频生成领域在近年来取得了爆发式进展。以 Wan2.2-TI2V-5B(7) 和 CogVideoX(8) 为代表的早期开源模型奠定了技术基础;随后,混元视频(HunyuanVideo)、可灵(Kling)、Seedance 2.0 等商业级模型进一步将生成质量推向实用水平。这些模型大多在海量文本-视频对上训练,部分还整合了 3D 感知、物理仿真等额外先验。在文本生成图像方面,Stable Diffusion 系列开创了开源生态,而 GPT-Image 2.0、Qwen-Image 等最新模型在指令遵循、文字渲染和复杂构图方面取得了长足进步。

据我们所知,尚无现有工作能够以简单的数据中心化方法将全部九种任务统一到单一模型中——更没有在如此有限的资源条件下。上述文本生成视频、文本生成图像等模型各自专精于单一任务,彼此之间无法复用参数或共享训练管线。UniGen 通过重用 Kiwi-Edit 强大的编辑骨干,并以巧妙的条件构建将其重新用于生成任务,实现了高数据效率,从而填补了这一空白。

3 方法

3.1 通过条件视频实现任务统一

我们将所有任务定义为从 (prompt, source_video, [ref_image]) 到 target_video 的映射。所有视频均为 81 帧、16 fps (约 5.06 秒)。源视频的构建方式如表1所示。

Table 1: 核心任务的源视频构建与任务定义。

任务	源视频构建	目标视频
文本生成视频	全白帧 (255)	生成的视频
文本生成图像	全白帧	静态视频(同一图像重复)
图像生成视频	第一帧 = 输入图像, 其余白帧	生成的视频
图像编辑	输入图像的静态视频	编辑后图像的静态视频
视频编辑	原始视频	编辑后的视频

提示词会附加一个任务前缀 (例如 `text-to-video#:`) 和一个描述预期行为的系统提示。这种设计确保模型仅凭条件视频和前缀提示就能区分不同任务。

3.2 数据构建管线

我们从多个公开数据源汇聚训练数据:

- 文本生成视频: OpenVid-1M (来自 OpenVidHD 的带字幕视频对)。
- 文本生成图像: OpenGPT-4o-Image (gen.json)。
- 图像编辑: Pico-Banana-400k (sft_with_local_source_image_path.jsonl) 和 OpenGPT-4o-Image (editing.json)。
- 视频编辑: ReCo (添加/移除/替换/风格)。

为将这些异构数据统一转换为模型可用的训练格式, 我们开发了一套数据生成管线, 其核心是一个自动化构建脚本 (`build_multitask_dataset.py`)。该脚本读取各数据源的原始标注文件, 根据任务类型按需动态生成对应的源视频 (全白帧或静态帧), 并将所有任务所需的训练样本统一汇总为一份标准化的 CSV 文件, 列包括: `prompt`、`src_video`、`target_video`。此外, 脚本内置了加权采样机制, 可按配置的比例平衡各任务的样本分布 (例如, 20% 文本生成视频、20% 文本生成图像、15% 图像编辑、25% 图像生成视频、20% 视频编辑), 从而避免训练过程中因数据不均衡导致的偏向性收敛。

3.3 内存高效训练

在单张 80GB GPU 上训练一个 5B 参数的 DiT 模型处理 81 帧视频, 至今仍是一项极具挑战性的任务。为实现这一目标, 我们实施了多项关键的内存优化技术:

- 梯度检查点: 在后向传播过程中动态重新计算激活值, 以计算开销换取显存空间;
- RoPE 缓存: 对给定 (f, h, w) 的 3D 旋转位置嵌入进行预计算并缓存, 消除重复分配开销;
- 8 位 Adam (bitsandbytes): 将优化器状态量化为 8 位精度, 优化器内存占用减少约 50%;
- Flash Attention / xformers: 通过分块计算和 IO 感知优化, 大幅降低注意力机制的显存峰值;
- 混合精度 (bfloat16) 与 autocast: 在保证训练稳定性的前提下降低计算精度;
- MLLM 上下文缓存: 对重复出现的提示词, 存储其经 MLLM 编码后的特征表示, 避免冗余前向传播。

凭借上述技术的协同作用, 我们成功在单张 A100 (80GB) GPU 上以 batch size 8 实现了 81 帧、480p 分辨率视频的 stable 训练。

3.4 推理

我们提供了一个统一的推理脚本 (`diffusers_Uni_Gen.py`), 该脚本覆盖了全部九种任务。用户只需指定任务类型、文本提示, 以及可选的源图像/视频和参考图像, 脚本便会自动构建相应的源帧并

调用模型完成推理。根据任务属性，输出会自动保存为视频文件（生成与编辑任务）或图像文件（文本生成图像与图像编辑任务）。

3.5 任务分类法

我们的框架支持九种任务，按两个正交维度组织：输出模态（图像 vs. 视频）和条件类型（纯文本、起始帧图像或参考图像）。表2总结了九种任务矩阵。

Table 2: 本框架统一的九种任务。“--”表示未定义该任务。

输出模态	纯文本	起始帧图像	参考图像
图像生成	1. 文本生成图像 (T2I)	–	2. 参考引导 T2I
图像编辑	3. 图像编辑 (IE)	–	4. 参考引导 IE
视频生成	5. 文本生成视频 (T2V)	6. 图像生成视频 (I2V)	7. 参考引导 T2V
视频编辑	8. 视频编辑 (VE)	–	9. 参考引导 VE

各任务的输入-输出规范如下：

- T2I - 文本 → 图像。
- RefT2I - 文本 + 参考图像 → 图像。
- IE - 源图像 + 文本指令 → 编辑后的图像。
- RefIE - 源图像 + 参考图像 + 文本指令 → 编辑后的图像。
- T2V - 文本 → 视频。
- I2V - 起始帧图像 → 视频。（第一帧完全等于给定图像；后续帧由模型预测。）
- RefT2V - 文本 + 参考图像 → 视频。（参考图像提供风格或身份，第一帧自由生成。）
- VE - 源视频 + 文本指令 → 编辑后的视频。
- RefVE - 源视频 + 参考图像 + 文本指令 → 编辑后的视频。

训练期间，所有任务均统一使用 81 帧、16 fps（约 5.06 秒）的视频格式，以确保模型充分学习完整的时序动态。在推理阶段，帧数可根据任务需求灵活调节：对于图像编辑和文本生成图像等静态任务，我们建议使用 9 帧或 33 帧，而非训练时的 81 帧。这是因为静态任务本质上不涉及时间维度上的运动变化，过长的帧序列会引入大量冗余计算，造成 GPU 显存和计算时间的无谓消耗；将帧数缩短至 9 帧或 33 帧，可在保持多帧条件一致性的同时，最大限度地释放计算资源、降低推理延迟，使单张 GPU 能够支撑更高的并发请求或更快的响应速度。对于视频生成和视频编辑等动态任务，用户可根据所需时长选择 81 帧或任意帧数，模型均能自适应处理。这一灵活的帧数调节机制，使得同一套模型权重能够兼顾高质量视频生成与高吞吐静态图像处理，充分体现了统一框架在资源利用效率上的独特优势。源视频的构建遵循第3.1节介绍的相同原则，参考引导的任务额外接收一张参考图像作为输入。

4 实验

我们通过定性演示、标准化基准和架构分析，全面评估 UniGen-LingXi-5B，以验证我们编辑优先的统一框架在数据受限条件下的有效性。

4.1 训练设置

数据集构建。 由于计算资源有限，我们精心构建了一个紧凑但平衡的包含 20,000 条样本的训练集，覆盖五项核心任务。初始每任务收集 2,000 条样本，我们应用加权采样策略以平衡任务复杂度和条件多样性，确保多任务梯度动态稳定，避免灾难性干扰。这一谨慎选择反映了我们的目标：证明即使在数据稀缺的条件下，也能有效训练统一模型。

学习率消融实验。 我们观察到，将学习率从 5×10^{-6} 提高到 4×10^{-5} 会导致损失不稳定，出现大幅尖峰，尤其是在文本生成图像任务上。我们推荐使用 1×10^{-5} 到 2×10^{-5} 来进行稳定的多任务训练。

实施细节。所有实验均在单张 NVIDIA A100 (80GB) GPU 上完成。本项目的完整周期历时数周，涵盖了大量工程性工作：从推理代码、训练代码到数据管线代码的开发与联调，每一部分都经历了反复迭代和验证。其中，训练代码的调试尤为艰巨——为在单张 80GB GPU 上实现 81 帧、720p 视频的稳定训练，我们投入了大量精力逐一攻克以下内存优化难点：

- 梯度检查点：通过在后向传播中重新计算激活值来以计算换内存；
- RoPE 缓存：缓存给定 (f, h, w) 的 3D 旋转位置嵌入，避免重复分配；
- 8 位 Adam(bitsandbytes)：优化器内存减少约 50%；
- Flash Attention / xformers：减少注意力内存；
- 混合精度(bfloat16)和 autocast；
- MLLM 上下文缓存：为重复的提示词存储编码后的 MLLM 输出。

上述每一个优化点的实现与调试都是独立的工作量，涉及对底层计算图、显存分配和训练稳定性的深入理解。在最终敲定所有训练方案后，模型在单张 GPU 上累计训练了约一周时间才收敛至稳定状态。这一周期反映了一名独立研究者在资源受限条件下的真实工作投入：没有大规模集群的试错便利，每一个优化决策都必须经过深思熟虑。尽管总投入巨大，但相比主流的大规模多 GPU 训练范式动辄数周甚至数月的周期，我们以单卡、20k 数据和一周训练即实现了 9 合 1 任务的全面功能验证，充分证明了编辑优先统一框架的卓越数据效率与实用价值。

Table 3: UniGen-LingXi-5B 的训练超参数。

参数	值
学习率	$5 \times 10^{-6} \rightarrow 4 \times 10^{-5}$ (预热后)
批次大小	8
梯度累积	1
预热步数	200
调度器	线性预热 + 余弦衰减
优化器	8 位 AdamW
帧数	81
分辨率	480×720 (max_pixels=345,600)
梯度检查点	启用
Flash Attention	启用

评估协议。遵循生成式建模的标准实践，我们优先考虑下游的感知和语义指标，而非训练损失。我们在三个公认基准上进行评估：GEdit-Bench（图像编辑）、OpenVE-Bench（视频编辑）和 DPG-Bench（文本生成图像），并辅以覆盖全部九项任务的定性案例研究。

4.2 核心能力总览

我们在多样化的测试提示词上进行推理，以展示本统一框架的功能范围。图像编辑、视频编辑和文本生成图像的代表性结果证实了以下几点：

- 图像编辑：模型在保持源身份和空间布局的同时，可靠地执行局部属性操作（例如添加配饰、移除物体）和全局风格迁移。包含多个条件的复杂指令也能以高结构保真度处理。
- 视频编辑：跨帧的时间一致性始终得到保持。参考引导的风格迁移（例如卡通化、油画）和局部编辑（例如物体替换）展现出稳定的运动追踪，无闪烁或身份漂移。
- 文本生成图像：模型在人像生成和结构化属性控制（例如颜色、纹理、空间关系）方面展现出强大的能力。然而，在复杂的多物体组合和细粒度背景合成方面偶尔会遇到困难，这反映了训练过程中对长尾场景数据有限接触的局限。

总之，这些结果确认了 UniGen-LingXi-5B 成功统一了编辑和生成的条件路由，在需要精确结构保持和局部修改的任务上表现尤为稳健。

4.3 主要任务：详细分析

下面我们对五项核心生成与编辑任务逐一进行更深入的剖析。

Table 4: OpenVE-Bench 结果 (Gemini-2.5-Pro 评估)。我们引用 Kiwi-Edit (Stage-3) 指标作为基线, 因为我们的架构在无性能损失的情况下保留了其预训练编辑先验。

方法	总体	全局风格	背景变化	局部变化	局部移除	局部添加
Runway Aleph	3.49	3.72	2.62	4.18	4.16	2.78
Lucy-Edit (5B)	2.22	2.27	1.57	3.20	1.75	2.30
ICVE (13B)	2.18	2.22	1.62	2.57	2.51	1.97
DITTO (14B)	2.13	4.01	1.68	2.03	1.53	1.41
OpenVE-Edit (5B)	2.50	3.16	2.36	2.98	1.85	2.15
Kiwi-Edit (Stage-3) [参考]	3.02	3.64	2.64	3.83	2.63	2.36
UniGen-LingXi-5B (本方法)	3.02	3.64	2.64	3.83	2.63	2.36

4.3.1 图像编辑(基础)

图3展示了一项基本的图像编辑操作: 将风景图像的天空改为夜景。结果显示天空变暗而前景保持不变, 证实了模型的基本编辑能力。关于图像编辑的更全面评估, 包括艺术风格迁移和局部结构修改, 将在第4.5节中呈现。



Figure 3: 基础天空替换结果。

4.3.2 视频编辑

视频编辑是我们统一框架的核心能力, 能够在保持跨帧时间一致性的同时进行精确的结构和风格修改。为定量评估这一能力, 我们采用了 Kiwi-Edit(1) 引入的 OpenVE-Bench 评估协议, 该协议从六个维度衡量性能: 总体 (Overall)、全局风格 (Global Style)、背景变化 (Background Change)、局部变化 (Local Change)、局部移除 (Local Remove) 和局部添加 (Local Add)。

由于 UniGen-LingXi-5B 继承了 Kiwi-Edit 预训练骨干, 基础编辑先验能力未出现退化, 我们直接引用其报告的指标作为强基线。这允许进行公平的、协议对齐的比较, 同时隔离我们统一 9 合 1 条件机制的影响。表4汇总了基准结果及代表性专用编辑器的对比。

input1	input2	kiwi-edit	output
Add a smiling woman with dark hair, wearing a dark purple V-neck shirt and a pearl necklace, sitting in a chair, looking towards the camera, positioned in the right half of the frame.			
Replace the black book with jellyfish on the cover in her hands with a white gift box with a red ribbon and bow.			
Convert the video into an Oil Impasto Painting style			

Figure 4: 视频编辑场景。

定性验证。图4展示了三个场景与 OpenVE-Bench 类别相一致的编辑场景：

- 局部添加 (Local Add): 给定指令“添加一位深色头发的微笑女性，身穿深紫色 V 领衬衫……”，模型在指定空间区域精确合成新主体，同时保持场景光照和时间一致性。
- 物体替换 (Local Change): 提示词“将封面上有水母的黑皮书替换掉……”触发了精确的语义替换。目标物体以最小的结构失真被替换，验证了模型细粒度的空间锚定能力。
- 全局风格迁移 (Global Style): 执行“将视频转换为油画厚涂风格”，生成了帧间一致的风格化效果。模型成功将运动动态与外观渲染分离，应用了连贯的艺术纹理，没有引入闪烁或时间抖动。

分析与权衡。我们的模型在 OpenVE-Bench 的所有维度上取得了平衡的性能，与 Kiwi-Edit Stage-3 基线紧密匹配。值得注意的是，我们在全局风格 (3.64) 和局部添加 (2.36) 上保持了强劲得分，证实了编辑优先范式能够有效处理结构植入和风格转换。在背景变化和局部移除方面相对于任务专用基线的轻微性能平台，反映了一种有意的架构权衡：我们的统一条件机制将时间稳定性和多任务通用性置于激进的单任务优化之上。这一设计选择确保了视频编辑在 9 合 1 框架内保持稳健，避免了模型仅在孤立编辑任务上微调时经常出现的灾难性遗忘。

未来迭代将探索显式空间掩码和参考引导解耦，以进一步增强细粒度控制，特别是针对复杂遮挡处理和高保真背景替换。

4.3.3 文本生成图像 (辅助任务)

“一幅美丽的日落” → 输出图像显示橙色和红色的色彩以及太阳的剪影，证实了静态视频训练对图像生成有效。关于文本生成图像的更全面评估，包括复杂提示词和定量指标，将在第4.6节中呈现。




Figure 5: 一幅美丽的日落。

4.3.4 文本生成视频(辅助任务)

我们评估模型在三个代表性场景中(图6)基于参考图像生成时间连贯视频的能力,从时空一致性、参考保真度和视觉美感三方面进行考量。

num	prompt	output
1	In the video, a woman is seen in a modern kitchen, preparing a meal. She is holding a wooden cutting board and appears to be in the process of chopping vegetables. The kitchen is well-equipped with a stainless steel sink, a countertop, and a refrigerator. On the countertop, there are various kitchen items such as a blender, a vase with flowers, and a jar of spices. The woman is dressed in a blue shirt and has a welcoming smile on her face. The overall style of the video is clean and modern, with a focus on the woman's cooking process and the kitchen's sleek design.	
2	The video features a woman in a white shirt, sitting in a cozy living room. She is gesturing with her hands, possibly explaining something or giving directions. The room is filled with natural light, and there are various objects scattered around, including a potted plant, a vase, and a book. The woman appears to be in a good mood, as she is smiling and seems engaged in the conversation. The overall style of the video is casual and relaxed, with a focus on the woman and her surroundings.	
3	The video features a man and a woman sitting side by side on a set with a cityscape in the background. The man is wearing a suit and tie, while the woman is dressed in a black dress. They are both seated on a white chair. The set has a blue and white color scheme. The cityscape in the background includes buildings and a street. The man and woman appear to be engaged in a conversation. The overall style of the video is professional and polished.	

Figure 6: 三个场景的示例视频提示词与生成帧。

(1)生活动作(厨房): 给定提示词“一位女性在现代厨房中切菜”,模型生成了时间连贯的序列,取景稳定,手-物交互自然,演播室灯光一致。虽然省略了一些次要元素(如水槽、搅拌机),但模型忠实地优先处理了核心动作和主要场景组件,展示了对结构合理性的关注,而非穷举式场景合成。

(2)休闲互动(客厅): 提示词“一位女性在舒适的房间中做手势”产生了流畅的面部表情和自然的手部动作。模型在帧间保持了空间布局和柔和自然光的统一,展示了稳健的单人运动建模能力,无时间闪烁、身份漂移或背景畸变。

(3)多人对话(脱口秀): 在这一正式访谈场景中,模型展现了强大的构图稳定性。两位主体的外貌、服装和眼神接触保持一致,而城市天际线背景保持静止且比例正确。光照模拟了专业演播室设置,凸显了模型处理多人空间关系和克制的对话动态的能力。

总结: 总体而言,模型成功生成了结构合理、时序平滑的视频,具有接近商业级别的美学质量。虽然细粒度的提示词遵循度(如精确物体位置)和微观细节(如手指关节或复杂道具物理)在数据受限的微调下仍受限制,但这些结果证实了编辑优先的骨干网络保留了可行的生成先验。这一能力可作为生活方式内容、虚拟数字人和商业片段的有效辅助模块,通过提示词工程、视频生成数据的定向扩展和运动专用适配器的集成,存在明确的改进途径。

4.3.5 图像生成视频(辅助任务)

我们评估模型将静态参考图像动画化为时间连贯视频序列的能力。如图7所示,我们展示了两个代表性场景:一支商业美妆广告和一幅风景肖像。

定性分析:

- 商业美学(案例 1): 以一张模特手持香水的参考图像为条件,模型生成了流畅的面部微表情和自然的头发飘动。光照和皮肤质感与高端商业标准保持一致。然而,所要求的“瓶子旋转”并未完全实现,且瓶身上的文字变成了乱码,凸显了在复杂物体操作和文字渲染方面的局限性。


prompt	frist_frame	outpup
Cinematic beauty advertisement, an elegant Asian woman with long wavy hair holding a red perfume bottle with a golden cap. She gently rotates the bottle to showcase its transparent texture and luxurious design, smiling warmly and making eye contact with the camera. She speaks naturally with subtle lip movements. Slow smooth zoom-in camera movement. Soft studio lighting with pink background, high-end commercial aesthetic, 4k resolution, realistic skin texture, delicate hair movement.		
A cinematic, photorealistic video of a beautiful young woman standing on a snowy coastal beach at sunset. She is wearing a vibrant red V-neck wool sweater that gently flutters in the cold sea breeze, with soft fabric draping and subtle wrinkles forming as it moves, demonstrating physically plausible cloth dynamics. Her long hair flows freely around her shoulders. Gentle waves roll onto the shore, creating foamy edges, while light snowflakes fall slowly and gracefully through the air. The scene maintains a serene atmosphere with soft natural lighting, featuring high temporal coherence and a slow, smooth camera pan to the right to capture the peaceful motion.		

Figure 7: 图像生成视频结果。左：提示词描述。中：静态参考图像（输入）。右：生成的视频帧（输出）。模型展示了高身份保持和时间稳定性，尽管在文本提示词与视觉先验冲突时会出现参考主导效应（例如案例 2 的服装颜色）。

- 风景肖像（案例 2）：在雪景海滩场景中，模型成功动画化了被风吹动的头发和背景中的海浪翻滚。主体的身份在帧间完美保持，无失真。值得注意的是，尽管提示词指定了“红色 V 领毛衣”，模型严格遵循了参考图像中的“深灰色上衣”。这表明了一种参考主导效应，即模型在文本指令与视觉先验冲突时优先考虑视觉保真度。

总结：图像生成视频能力可作为动画化肖像和静态场景的稳健辅助模块。该模型在身份保持和时间一致性方面表现出色，适用于数字分身和社交媒体内容等应用。然而，目前在复杂语义变化（例如通过提示词改变衣服颜色）和细粒度物体动态（例如特定产品交互）方面表现挣扎，提示未来迭代需要更强的文本-视频对齐机制。

4.4 扩展能力：参考引导的任务

在五项核心任务之外，我们的统一框架自然支持四项参考引导的任务，展示了编辑优先架构的可扩展性。

4.4.1 参考引导的图像编辑

UniGen-LingXi-5B 支持参考引导的图像编辑，实现语义级跨图像理解和动态组合。模型能够根据文本指令将参考物体自然地整合到目标场景中，同时保持空间布局和光照连贯性。然而，我们观察到明显的视觉保真度衰减：虽然语义类别保持稳定（例如“包”仍是包），但细粒度外观特征呈现出显著漂移——表现为颜色偏移、材质简化、结构比例调整以及高频细节损失（例如五金件、标志、文字）。这揭示了当前框架中“语义灵活性”与“像素级重建”之间的内在权衡。

CFG 调制与结构保真度分析：这种权衡与无分类器引导（CFG）的强度相关。在参考引导任务中，CFG scale 直接控制注入参考特征的权重。实验表明， $CFG \geq 7.5$ 会过度放大交叉注意力信号以进行局部参考对齐，压制底层几何先验，并引发结构失真（例如瓶身融化、标签变形、透视异常）。反之，在 $CFG = 5.0$ 时，模型优先考虑其结构先验，将参考条件视为“软约束”，从而保持几何稳定性和自然光照整合。尽管高频细节恢复略有折损，但基于结构完整性（SSIM）和特征对齐（DINO/CLIP）的消融研究证实， $CFG = 5.0$ 代表了当前架构的最佳工作点。因此，我们在 GEdit-Bench 等基准测试中统一采用 $CFG = 5.0$ 进行推理。该策略并非简单的约束放松，而是基于我们统一编辑框架的条件交互特性，主动缓解高引导尺度下的梯度冲突和结构坍塌。未来工作将探索解耦引导或轻量级显式参考适配器，以进一步超越“结构稳定性”与“细节保真度”之间的当前边界。

input1	input2	input3	output
An elegant lady is carefully selecting an exquisite blue bag from the boutique, while the salesperson is introducing the bag to her from the front			
Professional product photography features an elegant Asian female model holding a Lumière perfume bottle, gently showcasing the product. The model has long curly hair, exquisite makeup, and is wearing a white minimalist top against a pink background. She smiles as she brings the perfume bottle closer to the camera, while gently stroking the bottle with her other hand, highlighting the luxurious texture of the product. The perfume bottle is a square transparent glass bottle with a golden cap, containing pink perfume liquid, and labeled "Lumière". The soft studio lighting, shallow depth of field, high-end beauty makeup advertising style, 8K ultra-high-definition picture quality, exquisite details, and commercial photography quality are all evident.			

Figure 8: 参考引导的图像编辑结果。

4.4.2 参考引导的文本生成图像(初步研究)

UniGen-LingXi-5B 尝试在其编辑优先的架构中统一参考引导的生成。如图9所示,模型展示了基本的跨模态语义对齐:它能够从参考图像中识别物体类别(例如“包”或“香水瓶”),并尝试根据文本指令(例如“手持”)将其放置到场景中。

input1	input2	output
An elegant lady is carefully selecting an exquisite blue bag from the boutique, while the salesperson is introducing the bag to her from the front		
Professional product photography features an elegant Asian female model holding a Lumière perfume bottle, gently showcasing the product. The model has long curly hair, exquisite makeup, and is wearing a white minimalist top against a pink background. She smiles as she brings the perfume bottle closer to the camera, while gently stroking the bottle with her other hand, highlighting the luxurious texture of the product. The perfume bottle is a square transparent glass bottle with a golden cap, containing pink perfume liquid, and labeled "Lumière". The soft studio lighting, shallow depth of field, high-end beauty makeup advertising style, 8K ultra-high-definition picture quality, exquisite details, and commercial photography quality are all evident.		

Figure 9: 参考引导的文本生成图像:条件冲突和布局不稳定。

然而,我们在细粒度控制方面观察到了显著挑战:

- **条件冲突:** 参考图像中的强视觉特征往往压倒了对主体的文本描述。例如,模型生成了物体但忽略了提示词中的“亚洲女性”,或者物体的蓝色渗漏到主体的衣服上。这表明,在没有显式解耦机制的情况下,视觉信号容易主导交叉注意力权重。
- **布局不稳定:** 模型难以在生成的主体和参考物体之间维持逼真的空间关系,导致比例失真或出现伪影。

洞察与架构分析:

- **文本编码器瓶颈:** 当前架构继承自 Kiwi-Edit, 主要依赖 Qwen2.5-VL-3B 进行特征提取。虽然 Qwen 具有强大的通用视觉-语言理解能力,但当用作扩散模型的条件输入时,在长指令遵循和复杂空间关系解析方面可能表现出信息瓶颈。与专门为扩散模型设计的文本编码器(如 T5-XXL)相比, Qwen 的通用表征可能对细粒度控制不够敏感,导致模型“抓住要点但遗漏细节”。
- **架构权衡与未来方向:** 这表明我们的统一架构原则上支持参考引导的生成,但受限于当前的特征融合策略和编码器选择。

短期缓解: 通过简化提示词来降低文本编码器的解析负担(例如第4.4.1节描述的 $CFG = 5.0$ 策略)。

长期升级: 计划引入 T5-XXL 文本编码器或采用双文本编码器策略(Qwen 负责语义理解, T5 负

责特征注入)，以彻底解决文本条件被视觉条件淹没的问题。我们将此确定为模型迭代的关键方向。

4.4.3 参考引导的视频编辑

UniGen-LingXi-5B 支持通过推理时注入参考图像特征来进行参考引导的视频编辑。模型能够在保持时间连贯性和运动保真度的同时，将视觉属性（例如局部配饰、背景布局或全局艺术风格）从参考图像迁移到目标视频。我们的评估涵盖局部属性添加、背景替换和全局风格迁移，展示了编辑优先架构在视频领域的有效性。



Edit Type	input1	input2	input3	output
partial editing	Put on a pair of iconic red heart-shaped sunglasses for the girl.			
partial editing	Replace the background with a Chinese ink painting depicting a large golden mountain peak towering above rolling clouds.			
global replace	Reference-guided video style transfer. Transform the dancer into the exact style of the reference image: a Chinese fantasy character in a flowing light-blue and white elegant gown with golden ornaments, surrounded by glowing magical rings and floating swords. Strictly preserve the original dance movements, poses, and rhythm from the source video. Ensure temporal consistency across frames, avoid flickering, and render the background as a starry sky with clouds matching the reference.			
global replace	Transform the video into a 3D animation style like Pixar/Disney characters. Reference the provided image for character design: convert the woman to have long wavy brown hair, wearing a black high-neck long-sleeve dress with a wide black belt. CRITICAL: Strictly preserve the original action and pose. She is sitting on a chair, holding a smartphone up to the camera to show the app interface, and talking/explaining. Do NOT change her to a standing pose or dancing. Maintain her facial expressions, lip movements, and hand gestures exactly as in the source video. Use soft 3D rendering with smooth shading, avoid flat 2D cartoon look. Ensure the phone screen remains visible in her hands. Ensure temporal consistency across frames.			

Figure 10: Ref-VE: 局部配饰添加、背景风格化和全局风格迁移。

局部属性添加与背景替换 模型在局部编辑场景中展现了高精度的跨帧特征追踪：

- 局部配饰添加（案例 1）：以红色心形太阳镜为参考，模型成功地将配饰“佩戴”在人脸上。眼镜的轮廓和视角随头部运动自然变化，保留了原始面部特征、表情和光照——展示了强大的局部空间对齐能力。
- 背景风格替换（案例 2）：以一幅中国水墨画（金色山峰在翻滚云层之上）为参考，模型准确分离了原始室内背景，并以艺术风景替换。前景人物（手持电话、正在讲解）保持完整，包括动作、空间位置和环境光遮蔽——验证了稳健的前景-背景解耦机制。

保持运动的风格迁移 在全局风格迁移任务中，模型展示了在严格保持原始运动的同时应用参考风格的能力：

- 3D 动画风格迁移（案例 4）：源视频（真实人物坐在椅子上，手持智能手机讲解）被转换为皮克斯/迪士尼 3D 动画风格。参考图像提供了角色设计（头发、裙子）。输出成功转换了材质渲染（皮肤和衣物变为 3D 卡通风格），同时严格遵循关键约束：人物保持坐姿、手持电话，所有口型/手势与源视频匹配。这表明时间注意力机制有效锁定了运动骨架，防止风格注入干扰原始动作轨迹。

- 奇幻风格适配(案例 3):尝试在保留舞蹈节奏的同时将舞者转换为中国奇幻角色。模型迁移了整体色调和部分装饰元素,但复杂动态下的精细细节仍有改进空间——反映了当前架构中“轻度风格化”与“激进结构替换”之间的性能梯度。

能力边界与架构权衡 需要注意的是,我们框架的参考引导能力集中在局部属性编辑和风格/背景迁移上。当参考图像在主体语义上与源视频差异巨大时(例如将一个真实人物替换为外观完全不同的 3D 角色),模型会表现出特征抑制。这源于“编辑优先”架构的设计权衡:为确保时间一致性和运动保真度(视频编辑的核心需求),模型在去噪过程中对源视频的时间先验赋予更高注意力,从而限制了全局主体替换所需的强跨模态对齐。

这一边界并非架构缺陷,而是统一视频编辑模型中可控性与生成自由度之间的主动选择。当前版本优先考虑专业编辑工作流的高频需求:“保持动作、保持身份、修改属性”,而非激进的内容重构。

小结 总之,UniGen-LingXi-5B 成功支持了多种参考引导的视频编辑工作流,从局部配饰添加和艺术背景替换到全局风格迁移。其核心优势在于以极低的提示词工程成本维持高精度的运动保持和时间一致性。未来工作将探索显式跨帧参考注入模块(例如 Video ReferenceNet 或双条件适配器),以在保留当前运动保真度优势的同时,进一步扩展全局主体替换的能力边界。

尽管生成结果在所有情况下尚未达到照片级真实,但它们证明了统一框架是功能性的,并且模型已经学会了遵循任务指令以及利用参考图像进行引导编辑和生成。

4.4.4 参考引导的文本生成视频(RefT2V)

我们评估模型通过同时条件化于参考图像(用于视觉身份/风格)和文本提示词(用于动作/场景描述)来生成视频的能力。该任务对于虚拟数字人、数字叙事和个性化内容生成等应用至关重要。我们展示了两个代表性案例研究:一个真实感肖像动画和一个风格化 3D 角色生成。

案例研究 1: 真实感肖像动画(精品店场景)。 设定:给定一张精品店中女士的参考图像(图11,左上)和提示词:“一位优雅的女士正在精品店中仔细挑选图片中一款精致的蓝色包包。她正在正面介绍这款包包。”

优势:

- 服装与纹理保真度:模型成功保留了特定的服装组合(白色针织开衫搭配深蓝色上衣)。针织衫的纹理在视频中得到写实渲染,与参考图像保持高度视觉一致性。
- 背景一致性:背景中模糊的服装架与参考图像的景深和语义上下文(精品店设置)相匹配。
- 面部动画:生成的视频具有自然的微表情,包括眨眼和与说话(“介绍”)一致的嘴唇运动,展示了稳健的肖像动画能力。

劣势:

- 属性漂移(头发):在头发属性上观察到显著差异。参考图像中头发为深色、略显凌乱(可能束起),而生成的视频显示为浅棕色、短直发(波波头)。这表明在文本引导下细粒度身份保持方面存在失败。
- 物体幻觉/提示词忽视:提示词明确要求“挑选一款精致的蓝色包包”并“介绍这款包包”。然而,生成的视频显示女士仅仅站立说话,手中没有可见的包包,也没有与物体的交互。这揭示了在物体锚定和复杂动作实现方面的局限。
- 动作不匹配:“挑选”动作暗示身体运动和手部交互,而输出中缺失(身体静止,仅头部运动)。

案例研究 2: 风格化 3D 角色生成(奇幻场景)。 设定:给定一张身着黑裙的 3D 卡通女孩参考图像(图11,左下)和提示词:“一个可爱的 3D 卡通女孩……骑着一匹雄伟的白马,手中握着一个发光的 URL 链接符号……”

优势:

- 场景构图:模型有效合成了一幅包含角色和大型动物(马)在户外环境中的复杂场景,保持了所要求的“皮克斯风格”美学。
- 动作实现:骑马姿态自然实现,展示了对人-马空间关系的理解。



prompt	frist_frame	output
An elegant lady is carefully selecting an exquisite blue bag from the picture in a boutique. She is introducing the bag from the front		
A cute 3D cartoon girl with brown hair in a black dress riding a majestic white horse, holding a glowing URL link symbol in her hand. Background is a dreamy sky with soft clouds. Pixar style, magical atmosphere.		

Figure 11: 参考引导的视频生成结果。上方：真实感精品店场景（参考：图 22，输出：视频 7）。模型保留了服装纹理，但未能保持头发属性，且忽略了提示词中的“蓝色包包”物体。下方：风格化 3D 角色场景（参考：图 21）。模型生成了连贯的骑马场景，但简化了服装细节（裙子变为裤子），且未能渲染特定的“URL 符号”。

劣势:

- 服装简化: 参考图像中是一条独特的带有双扣腰带的长黑裙。生成的输出简化为黑色上衣和裤子, 失去了优雅的轮廓和特定的配饰细节。
- 符号元素失败: 提示词要求“手中握着一个发光的 URL 链接符号”。输出显示胸部区域有一团模糊的蓝光, 而非手中持有的清晰符号, 表明在生成特定符号对象方面存在困难。

综合与架构洞察: 这些案例揭示了 UniGen-LingXi-5B 在参考引导生成中的一致模式:

1. 全局风格与纹理的优势: 模型擅长保留全局属性, 如服装颜色、材质纹理(针织衫)和整体艺术风格(3D 卡通 vs. 真实感)。
2. 细粒度身份与物体交互的劣势: 模型在以下方面存在困难:
 - 特定特征保持: 头发风格/颜色漂移(案例 1)和服装结构简化(案例 2)。
 - 复杂提示词遵循: 未能生成所要求的物体(蓝色包包、URL 符号)或执行复杂交互(挑选、手持)。

根本原因分析: 这种行为表明当前的参考注入机制主要在语义/粗粒度层面运行(匹配“人物”、“黑色衣服”、“精品店”), 而非实例/密集层面(匹配精确的发丝、特定的裙子剪裁)。此外, 模型优先考虑时间稳定性(生成平滑的谈话头像或稳定的骑乘姿态), 而非提示词驱动的物体插入, 这可能是由于编辑优先的训练范式侧重于修改现有像素, 而非从文本中幻觉生成新的复杂物体。

未来方向: 为解决这些限制, 未来迭代应探索:

- 密集参考对齐: 使用类似 ControlNet 的机制或更高保真度的 IP-Adapter, 以强制执行对参考细节(头发、配饰)的严格遵循。
- 以物体为中心的训练: 纳入包含显式物体交互(持握、穿戴、使用)的数据集, 以提升模型将文本提示词锚定到视觉物体的能力。

4.5 图像编辑评估: 深度剖析

为彻底评估 UniGen-LingXi-5B 的图像编辑能力, 我们设计了四个具有挑战性的提示词, 涵盖局部结构修改(提示 2)和高阶艺术风格迁移(提示 1、3、4)。所有提示词均应用于同一位年轻女性的源肖像。我们将模型与五个最先进的基线进行比较: GPT Image1.5(高)、Nano Banana2、Nano Banana Pro、FLUX.2 [max] 和 Seedream4.0。

4.5.1 评估提示词

P1 “将整张图像转变为梵高《星月夜》风格。”

P2 “将上衣改为低胸 V 领款式。”

P3 “赛博朋克肖像。短发女孩站在雨湿的未来城市中, 霓虹粉色和青色的灯光反射在她的脸上。皮肤上隐约可见发光的微电路, 眼神锐利、仿生。背景是拥挤的赛博朋克街道, 全息广告林立。高饱和度, 电影质感。”

P4 “传统中国水墨画风格。女孩以稀疏笔触渲染, 强调线条的流动和墨的韵律。云雾和极简的山水留下大面积留白。仅用黑、白、灰及一抹朱红。”

4.5.2 定性结果

图12展示了所有模型的输出图像。UniGen-LingXi-5B 展现出深度的语义重构, 而非肤浅的滤镜叠加。对于 P1(梵高), 我们的模型产生了厚重的厚涂肌理和漩涡状的笔触, 真正模仿了油画质感, 而竞品往往仅施加了一层“照片滤镜”效果。对于 P2(局部编辑), 我们的模型精确修改了领口, 解剖学上合理的明暗过渡且无边缘伪影, 展示了强大的几何理解能力。对于 P3(赛博朋克), 我们的模型将发光电路物理性地融入皮肤, 实现了真正的赛博格改造, 而其他模型主要添加了彩色灯光。对于 P4(水墨), 我们的模型捕捉到了湿墨渗化和富有韵律的书法线条, 达到了传统中国画空灵的“气韵”; 相比之下, 基线作品要么产生去饱和的素描, 要么是僵硬的写实肖像。



prompt/input	GPT Image 1.5 (high)	Nano Banana 2	Nano Banana Pro	FLUX.2 [max]	Seedream 4.0	Ours (UniGen-LingXi-5B)
prompt1 + 						
prompt2 + 	/					
prompt3 + 						
prompt4 + 	/					

Figure 12: 四个提示词 (P1-P4) 图像编辑结果的定性对比。每张提示词下, 输出图像从左到右依次为: 输入、GPT Image1.5 (高)、Nano Banana2、Nano Banana Pro、FLUX.2 [max]、Seedream4.0, 以及我们的方法 (UniGen-LingXi-5B)。

4.5.3 人类偏好评估

我们聘请 Qwen3.6-Plus 作为独立裁判, 在五个指标 (1-5 分) 上对每个模型打分: 指令遵循度 (IF)、风格表现力 (SE)、身份保持 (ID)、视觉和谐 (VH) 和细节与纹理 (DT)。表5汇总了结果。

Table 5: Qwen3.6-Plus 给出的量化评分 (越高越好)。

模型	IF	SE	ID	VH	DT
GPT Image1.5 (高)	2.5	3.0	3.5	4.0	3.5
Nano Banana2	3.0	2.5	4.0	3.5	3.0
Nano Banana Pro	3.5	2.5	4.5	4.0	3.5
FLUX.2 [max]	3.0	3.5	4.0	3.5	4.0
Seedream4.0	4.0	3.5	5.0	4.5	4.0
UniGen-LingXi-5B (本方法)	5.0	5.0	4.0	5.0	5.0

UniGen-LingXi-5B 在指令遵循度、风格表现力、视觉和谐和纹理质量方面获得了满分。在身份保持方面获得 4.0 分——这是一个有意的权衡, 以在提示 3 和 4 中实现极致的艺术重新诠释, 其中激进的纹理变化 (电子电路、水墨笔触) 自然会改变原始外观。

4.5.4 GEdit-Bench 基准测试

为进一步量化通用图像编辑能力, 我们在公开的 GEdit-Bench 上评估模型, 该基准包含 11 个编辑任务类别, 涵盖英文和中文指令。所有评估均使用 VIEScore 指标, 以 Qwen2.5-VL-72B 为骨干。表6报告了英文和中文分组的语义一致性 (Q_SC)、感知质量 (Q_PQ) 和总体得分 (Q_O)。

我们的模型在英文和中文上的总体 Q_O 分别为 5.305 和 5.628。图13提供了各任务雷达图分解 (Overall 子集, 英文), 图14则对比了我们在两个语言子集上与竞争模型的平均表现。

Table 6: GEdit-Bench(全集)上与 Qwen2.5-VL-72B 裁判的量化评估。所有指标越高越好(↑)。“--”表示该模型不支持对应语言。

模型	GEdit-Bench-EN(全集)			GEdit-Bench-CN(全集)		
	Q_SC	Q_PQ	Q_O	Q_SC	Q_PQ	Q_O
InstructPix2Pix	4.746	6.913	4.578	--	--	--
MagicBrush	5.752	7.069	5.558	--	--	--
AnyEdit	3.713	6.730	3.635	--	--	--
OmniGen	6.845	6.700	6.352	--	--	--
Step1XEdit	7.388	7.279	7.067	7.490	7.384	7.212
Step1XEditv1.1	7.652	7.408	7.346	7.532	7.370	7.240
Gemini	7.274	7.327	6.971	5.622	7.370	5.525
Doubao	7.353	7.651	7.230	7.098	7.676	7.040
GPT4o	7.847	7.705	7.692	7.726	7.652	7.552
UniGenLingXi5B(本方法)	5.673	6.667	5.305	6.024	6.746	5.628




Figure 13: UniGen-LingXi-5B 在英文 GEdit-Bench (Overall 子集) 上的雷达图。三个维度对应 Q_SC、Q_PQ 和 Q_O。模型在主体添加、移除和颜色变更方面表现出色,但在文本编辑和运动变化方面落后。




Figure 7: VIEScore of Each Sub-task in GEdit-Bench. All the results are evaluated by GPT-4o.

Figure 14: UniGen-LingXi-5B 与四个强基线在 GEdit-Bench 全集 (EN 和 CN) 上的平均 Q_SC、Q_PQ 和 Q_O 对比。我们的模型语义一致性较低,但感知质量具有竞争力,尤其是在中文子集上。

任务级性能诊断 表7进一步拆解了各任务 Q_O 得分 (Overall 子集, Qwen2.5-VL-72B 评估)。

Table 7: UniGen-LingXi-5B 在 GEdit-Bench (Overall 子集) 上的各任务表现。任务按能力水平分组。

任务	EN Q_O	CN Q_O
强(≥ 6.5)		
subjectadd	7.087	7.176
color_alter	6.863	7.045
subjectremove	6.733	6.348
中等(5.0-6.5)		
background_change	6.209	6.398
material_alter	6.410	6.429
style_change	6.242	5.870
subjectreplace	6.354	6.787
弱(3.5-5.0)		
tone_transfer	4.777	5.974
motion_change	4.012	4.483
ps_human	4.007	3.756
极弱(≤ 3.5)		
text_change	1.582	1.642

从雷达分析和详细得分中得出的关键观察：

- 局部属性编辑能力强：主体添加、移除和颜色变更的 Q_O 得分在英文上均超过 6.7，中文上在 6.3-7.1 之间。这验证了编辑优先的统一架构能够仅用 2 万条训练样本就有效处理以物体为中心的修改。
- 全局风格和背景操作可接受：风格变更（英文 6.24）和背景变更（英文 6.21）达到可用水平，表明模型能够执行超越简单滤镜的整体重渲染。
- 文本、运动和人像编辑方面的弱点：text_change（1.58-1.64）、motion_change（约 4.0）和 ps_human（约 4.0）得分急剧下降。这是预期之中的，因为我们的训练集（源自视频编辑数据）包含极少的文本渲染、动态运动编辑或高分辨率人脸精修样本。
- 音调迁移表现中等：tone_transfer（英文 4.78，中文 5.97）表明模型在一定程度上能够调整全局光照，但在细粒度光照一致性方面有所挣扎。

性能差距归因 我们将观测到的差距归因于三个主要因素，所有这些因素都源于我们当前有限的数据和计算预算：

1. 数据分布偏差：我们的 2 万条训练样本主要来自视频编辑数据集，这些数据集富含以主体为中心的编辑，但缺乏文本渲染、运动合成和高分辨率人像精修样本。
2. 视频编辑的架构权衡：9 合 1 统一设计跨任务共享参数。为保持视频编辑中的时间一致性，模型将结构先验置于像素级文本精度之上，损害了 text_change 和 motion_change。
3. 条件机制局限：隐式交叉注意力对全局风格和局部物体添加效果良好，但对细粒度局部控制（例如精确唇部修改或精确角色放置）效果较差。显式参考解耦可以缓解这一问题。

积极发现 尽管绝对得分中等，但两项结果令人鼓舞：

- 数据效率：仅用 2 万条训练样本（比典型专用模型少两个数量级），我们的模型已在局部编辑任务上取得了有竞争力的结果。这展示了编辑优先统一范式卓越的采样效率。
- 9 合 1 统一的概念验证：单一模型能够处理五项核心任务加四项参考引导扩展任务，并在多种编辑类型上仍达到可用性能（Q_O > 5.0），这一事实验证了核心研究假设。令人鼓舞的感知质量（Q_PQ = 英文 6.667，中文 6.746）进一步表明编辑结果在视觉上是可信的。

4.5.5 四大显著优势

我们的编辑模型展现出以下优势：

1. 高精度局部控制：对于结构编辑，模型准确推断几何、光照和物理，实现无缝融合，无光晕或扭曲。
2. 风格迁移中的真正重构：UniGen-LingXi-5B 不是施加全局滤镜，而是根据目标艺术媒介（油画厚涂、电子植入或水墨）重新渲染图像。
3. 自适应光照与上下文：新引入的元素（霓虹反射、水墨渗透）自动适应原始场景的光照和几何，消除了其他模型中常见的“粘贴”外观。
4. 数据高效的泛化：以仅 2 万对样本从视频编辑骨干（Kiwi-Edit）微调而来，模型在多样化任务（局部编辑、风格迁移、物体替换）上展现出卓越的鲁棒泛化能力。

4.5.6 小结

UniGen-LingXi-5B 为指令驱动的图像编辑设立了新的最先进水平，尤其是在艺术风格迁移和结构敏感的局部编辑方面。它弥合了“像素级融合”（开源基线中常见）与语义级重构之间的鸿沟，为创意专业人士提供了强大的引擎。

4.6 文本生成图像评估：深度剖析

我们通过定性案例研究和严格的定量基准测试来评估 UniGen-LingXi-5B 的文本生成图像能力。虽然我们的主要关注点是视频编辑，但评估 T2I 能力可以揭示模型底层的语义锚定和生成先验。

4.6.1 评估提示词

我们设计了四个具有挑战性的提示词，以测试生成的不同方面：复杂材质描述（提示 1）、电影级光照（提示 2）、带有纹理的广阔背景（提示 3）以及物体-人物交互（提示 4）。

- P1 “一张引人注目的女性特写肖像，她裂纹金属质感的铜色双手框住脸庞。鲜艳的蓝红眼妆与光滑白皙的皮肤和柔和背景形成鲜明对比，创造出大胆的超现实构图。她流露出一种不确定的神情。”
- P2 “一张光线锐利的中年男性肖像，戴着细框眼镜，身穿深色外套内搭白色领衬衫。他专注地凝视一侧，脸部一半被暖光照亮，背景隐入深沉的阴影。表情若有所思，几近警觉，仿佛在对话中途被捕捉。身后，一个红黑色调的条纹靠垫增添了微妙的纹理，与他额头和眼镜上清晰的高光形成对比。整体氛围是沉思和电影感的，在温暖与张力之间取得平衡。”
- P3 “一张富有戏剧性的黑白肖像，一位年轻人披着连帽衣，脸部被帽兜的暗褶框住。他们的肤色和颧骨上细腻的光泽与深邃的阴影形成了醒目的色调对比。他们的眼神锐利，平静而坚定地直视镜头。衣物的纹理清晰可见：它致密、略带风霜，轻薄的褶皱捕捉着光线。背景中，一片浩瀚、失焦的风景暗示着开阔的空间——或许是远处的平原或水域——尽管细节依然柔软而抽象。”
- P4 “拍摄一张头肩肖像，一位雀斑红发小提琴手身穿藏青色西装外套，柔和的窗光，85mm f/1.8 镜头，温柔微笑但眼神严肃，色调柔和。”

4.6.2 定性分析

我们使用相同的随机种子，未经任何后处理，为每个提示词生成了图像。

我们的分析揭示了一个清晰的“专精”模式：UniGen-LingXi-5B 擅长生成高质量、令人愉悦的人脸，但在复杂非人物体、背景细节和细粒度材质纹理方面表现挣扎。

- P1(铜色双手)：模型生成了具有金属色调的双手，但遗漏了“裂纹”纹理。眼妆被夸大，失去了细微的表情。
- P2(电影光效)：光照均匀，缺乏鲜明的明暗对比。背景中的条纹靠垫被严重模糊。
- P3(连帽人物与风景)：最严重的失败——模型将所要求的广阔户外风景替换为纯白背景。织物纹理被渲染为平滑而非“风霜”。
- P4(小提琴手)：模型完全未能生成小提琴，只生成了一幅肖像。“雀斑”细节也几乎不可见。




prompt/input	GPT Image 1.5 (high)	Nano Banana 2	Nano Banana Pro	FLUX.2 [max]	Seedream 4.0	Ours (UniGen-LingXi-5B)
prompt1						
prompt2						
prompt3						
prompt4						

Figure 15: 四个文本生成图像提示词(P1-P4)的生成图像。模型产生了高质量的人脸，构图稳定，但在复杂非人物体（小提琴）、写实背景（坍塌为白色）以及细粒度材质纹理（裂纹铜色、风霜织物）方面遇到了困难。

4.6.3 DPG-Bench 定量评估

为提供标准化评估，我们在 DPG-Bench 上评估 UniGen-LingXi-5B，这是一个全面的文本生成图像基准。表8将我们的模型与最先进的生成器进行了对比。




Figure 16: 不同模型在 DPG-Bench 上的性能对比（左：L1 类别，右：UniGen-LingXi-5B 的细粒度 L2 得分）。

关键发现：结构化控制能力突出 vs. 组合推理存在差距 如表8所示，UniGen-LingXi-5B 的总体得分为 69.44。虽然落后于专用 SOTA 生成器（85-88），但模型在结构化视觉控制方面表现出竞争力：

- 关系(85.58)：超越了 PixArt- α (82.57)等成熟的开源基线，表明强大的空间和语义关系建模能力。
- 属性(82.32)：展现出稳健的属性绑定能力，可与早期生成模型（如 SDXL:80.91）相媲美。

Table 8: DPG-Bench 评估结果(1024×1024 分辨率)。加粗:类别最优。注意:UniGen-LingXi-5B 使用 2 万条样本以统一 9 合 1 架构训练,而竞品均为专用 T2I 模型。

模型	全局	实体	属性	关系	总体 ↑
SD v1.5	74.63	74.23	75.39	73.49	63.18
PixArt- α	74.97	79.32	78.60	82.57	71.11
SDXL	83.27	82.43	80.91	86.76	74.65
Playground v2.5	83.06	82.59	81.20	84.08	75.47
Hunyuan-DiT	84.59	80.59	88.01	74.36	78.87
Janus	82.33	87.38	87.70	85.46	79.68
PixArt- Σ	86.89	82.89	88.94	86.59	80.54
Emu3-Gen	85.21	86.68	86.84	90.22	80.60
Janus-Pro-1B	87.58	88.63	88.17	88.98	82.63
DALL-E 3	90.97	89.61	88.39	90.58	83.50
FLUX.1 [Dev]	74.35	90.00	88.96	90.87	83.84
SD3 Medium	87.90	91.01	88.83	80.70	84.08
Janus-Pro-7B	86.90	88.90	89.40	89.32	84.19
HiDream-I1-Full	76.44	90.22	89.48	93.74	85.89
Lumina-Image 2.0	-	91.97	90.20	94.85	87.20
Seedream 3.0	94.31	92.65	91.36	92.78	88.27
GPT Image 1 [High]	88.89	88.94	89.84	92.63	85.15
Qwen-Image	91.32	91.56	92.02	94.31	88.32
UniGen-LingXi-5B(本方法)	78.83	80.20	82.32	85.58	69.44

Table 9: UniGen-LingXi-5B 的关键差距(DPG-Bench 1024)。红色:得分 < 60。

类别	得分	根本原因	未来方向
L1 类别			
其他(Other)	50.80	缺乏复杂构图数据;扩散模型幻觉	定向数据增强(思维链提示)
属性(Attribute)	82.32	-	-
关系(Relation)	85.58	-	-
实体(Entity)	80.20	-	-
全局(Global)	78.83	中等布局复杂度	-
关键子类别			
其他 - 计数(Count)	46.50	扩散模型缺乏显式计数模块	数值嵌入 + 计数损失
属性 - 大小(Size)	59.09	相对尺度需要参考框架	成对尺度对比数据
其他 - 文本(Text)	68.00	像素级拓扑不稳定	OCR 引导监督

- 实体(80.20):保持了可靠的对象完整性和局部细节生成。

然而,总体得分被“其他”类别(50.80)严重拉低,该类别涵盖了复杂的组合指令和长尾概念。这揭示了一个清晰的结构性失衡:模型在具体的、视觉锚定的属性方面表现出色,但在抽象推理和复杂的多物体组合方面有所挣扎。

细粒度分析:结构性差距 表9提供了性能差距的详细拆解。这些缺陷并非均匀分布,而是集中在需要抽象推理或符号锚定的特定领域。

结构性差距分析:

1. 数据覆盖:我们的 2 万条训练样本主要源自视频编辑数据集,这些数据集侧重于局部属性操作,而非复杂的多物体组合。因此,模型缺乏对需要精确计数(Other-Count: 46.5)或逻辑推理的长尾提示词的接触。
2. 机制局限:扩散模型本质上运行在连续像素分布上,缺乏用于计数或符号文本渲染的显式离散机制。没有专用模块(例如数值嵌入或 OCR 引导),模型倾向于幻觉数量或模糊字符拓扑。
3. 相对尺度建模: **Attribute-Size** (59.09)的低分反映了在没有显式参考框架的情况下建模相对概念(“大/小”)的挑战。潜在空间压缩可能进一步模糊细粒度的尺度区分。

这些差距并非统一架构的根本缺陷,而是表明未来的提升将来自定向数据增强和任务特定监督,而非简单的规模化扩展。

与领先模型的对比 表10总结了基于我们定性观察和 DPG-Bench 指标的 UniGen-LingXi-5B 相对于五个代表性基线的相对优势与劣势。

Table 10: 文本生成图像生成器的定性对比。

模型	人脸质量	物体准确性	背景	纹理细节	关系/属性
GPT Image 1.5	高	高	丰富	优秀	强
Nano Banana Pro	良好	良好	良好	良好	均衡
FLUX.2 [max]	良好	高	丰富	非常好	强
Seedream 4.0	非常高	非常高	丰富	优秀	强
本方法 (UniGen-LingXi-5B)	高	低	非常差	中等	有竞争力

我们的模型在生成有吸引力的人脸和结构化属性(关系:85.58)方面具有竞争力,但在生成非人物体(例如小提琴)、写实背景(倾向于坍塌为白色)和细腻表面纹理方面显著落后。

4.6.4 T2I 的讨论与未来方向

观察到的“有偏”行为——结构化控制能力强而复杂组合能力弱——可归因于训练数据集的构成以及编辑优先统一框架的架构权衡。我们的模型主要在肖像为中心和局部编辑数据上微调,这鼓励生成器产生安全、居中的人脸,而忽略环境和物体细节。

为改进文本生成图像的泛化能力,我们计划:

- 重新平衡训练数据:纳入更大比例的包含复杂背景、多物体和丰富纹理的图像。
- 增强推理能力:使用明确要求物体和逻辑关系的提示词进行增强,并引入思维链(CoT)风格的提示词调优。
- 任务特定模块:引入轻量级适配器用于计数(数值嵌入)和文本渲染(OCR 引导),以解决 DPG-Bench 中识别的关键差距。
- 背景感知损失:纳入更强的背景感知损失,或使用高质量文本生成图像模型的合成数据来教授更好的场景生成。

4.6.5 文本生成图像结论

UniGen-LingXi-5B 作为一个胜任的人像为中心、结构感知的文本生成图像引擎,能够可靠地生成美观的人脸,并具有强大的关系理解能力(85.58)。然而,受限于数据覆盖,它目前不适合生成复杂场景、精细物体或电影级光照。对于需要对属性和关系进行高可控性的应用(例如头像创建、结构化编辑),其表现可接受;对于具有复杂逻辑的全场景生成,它仍然是一个基线。未来工作必须通过专门的数据收集和定向监督来解决观察到的背景坍塌和物体遗漏问题。

5 讨论

我们对 UniGen-LingXi-5B 作为 9 合 1 框架的全面评估揭示了一个优势与边界交织的微妙图景。在此,我们将关键观察综合为总体性的架构洞察和清晰的未来路径,特别强调我们在资源受限设置下的意义。

编辑优先假设的效率。模型在图像编辑方面的 SOTA 表现以及对视频编辑先验的精准保持,仅用 2 万条样本便得以实现,这是对编辑优先范式的有力验证。通过从编辑骨干出发,模型继承了一个针对结构理解、身份保持和局部操作而优化的丰富特征空间。这一基础被证明具有高度可迁移性和显著的采样效率,使得生成能力的快速获取成为可能,而不会对核心编辑功能造成灾难性遗忘。

通用性-精确性权衡。模型在细粒度生成方面的局限(例如精确文本渲染、计数、复杂物体合成)并非随机失败,而是源于我们设计中的一个根本性权衡。为维持时间一致性和多任务稳定性,统一架构严重依赖于其编辑骨干的强结构先验。这种优先排序在“修改”任务(编辑)中产生了优异的结果,但内在限制了模型进行无约束的、对离散符号细节的“自由形式合成”的能力。这是一个主动的设计选择:我们优先考虑一个稳健、通用的基础,而非一个不稳定的“万金油”。

资源受限验证的意义。本工作的一个独特贡献在于证明了在极端资源约束下实现这种统一是可能的:单张 A100 GPU、12 小时训练,仅 2 万条数据点。这一配置对于大多数学术实验室和独立研究者而言是可及的,从而民主化了统一生成模型的研究。我们的结果表明,大规模计算并非探索多任务

统一的先决条件；相反，编辑优先条件等架构创新能够解锁高数据效率。在此有限预算下，对剩余弱点的透明记录提供了精确的规模化路线图：我们确切地知道哪些子任务（计数、文本渲染、细节物体插入）将从额外数据和定向模块中获益最多。这把资源限制从局限转变成了一个指导未来投资的受控实验。

通用编码器的信息瓶颈。在 Ref-T2I 中观察到的“条件冲突”以及 I2V 中的参考主导效应，凸显了一个关键的架构瓶颈：依赖一个通用 MLLM (Qwen2.5-VL) 作为主要条件编码器。其输出针对通用视觉-语言理解进行了优化，而非扩散模型所需的精确空间和细粒度控制。这促使未来转向双编码器架构。

将边界转化为规模化路线图。对我们模型具体弱点的透明记录是一项关键贡献。我们细粒度的 DPG-Bench 和 GEdit-Bench 分析表明，性能底线并不均匀；它集中在明确定义的子领域 (Other-Count: 46.5, text_change: 1.58)。未来的规模化努力可以是高度定向的，聚焦于为这些精确的子任务增强数据并引入轻量级专用模块（例如数值嵌入），而非盲目地扩大数据量。这一洞察对于高效、计算最优的研究至关重要。

6 结论与未来工作

我们提出了 UniGen-LingXi-5B，一个资源高效、九合一的统一多模态生成与编辑框架。通过将所有任务重新表述为条件视频生成，并建立在编辑优先的理念之上，我们成功地将五项核心任务和四项扩展的参考引导任务整合到单一、未修改的模型中——全部在单张 GPU 上仅用 2 万条样本完成训练。我们的方法被证明具有非凡的采样效率，在图像编辑方面取得了最先进的结果，同时保留了基础的视频编辑先验，并展示了可行的生成技能。在如此严峻的资源约束下，全部九项任务都能功能性地实现，这一事实凸显了编辑优先统一作为更广泛研究社区实用、可规模化范式的潜力。

通过严格而透明的分析，我们记录了模型的性能边界，揭示了一个根本性的通用性-精确性权衡，以及来自通用编码器的信息瓶颈。这些诚实的评估并未削弱本文的贡献，反而为未来的改进提供了精确的、数据驱动的路线图。

本工作的意义不仅在于展示了九合一统一的可行性，更在于验证了一条“编辑优先、条件构建统一”的方法论路径。这一方法论具有极强的可迁移性——未来任何更强大的 DiT 骨干网络或视觉-语言模型，都可以沿袭我们的范式，以极低的适配成本实现更多任务的统一。

展望未来，我们规划了一条从“视觉统一”到“通用智能引擎”的三阶段演进路线：

1. 近期——定向能力增强与规模化验证：我们将直接解决已识别的可操作瓶颈——计数推理、文本渲染和复杂空间组合——通过专用数据增强、数值推理模块以及双编码器架构以实现更精细的条件控制。同时，我们将把训练数据集规模扩大至十万条甚至百万条以上，明确地重新平衡其向长尾组合和场景多样性的方向，在更大规模上验证编辑优先范式的有效性。在此基础上，我们还将探索在统一架构中引入稀疏专家混合 (Mixture-of-Experts, MoE) 机制。本文观察到的“通用性-精确性权衡”提示我们，单一的共享前馈网络可能是多任务统一的一个根本性瓶颈：编辑任务需要结构保持能力，而生成任务则需要自由合成能力，两者在参数层面存在天然张力。MoE 为化解这一冲突提供了一条优雅的路径——通过任务感知或特征感知的路由器，让不同的专家子网络依据任务特性动态激活，编辑类专家专注于局部修改与时空一致性，生成类专家则负责高多样性的自由合成。这种稀疏激活机制有望在不显著增加推理成本的前提下，提升所有九项任务的整体性能，从根本上缓解当前观测到的编辑-生成冲突。
2. 中期——从视觉统一到音视频联合生成：当前框架已证明了视觉模态内统一的可能性，下一步我们将横向扩展至音频模态。通过引入音频编码器作为额外条件，模型将支持视频到音频 (Video-to-Audio) 和音频到视频 (Audio-to-Video) 等新任务，形成完整的多媒体内容创作闭环。这对于虚拟主播、数字人和短视频自动化生产等应用场景具有直接的产业价值。
3. 远期——向世界模型与具身智能演进：编辑优先框架对“动作保持、结构保留”的核心能力，恰好暗合了世界模型对时空一致性的根本需求。我们将逐步引入物理先验（刚体碰撞、流体运动）、显式 3D/4D 表征以及因果推理能力，使模型从“生成视觉上合理的像素”迈向“预测物理上可信的未来”。最终，这一能力将赋能具身智能体：将当前基于文本指令的视频编辑能力类比迁移至机器人操作场景，实现“语言指令 目标状态预测 动作序列规划”的完整闭环。这将为通用人工智能在物理世界中的落地提供关键的感知-规划-推理基础设施。

这一演进路线图的每一步，都建立在我们当前“编辑优先、资源高效”这一严谨概念验证的基石之上。我们公开发布所有模型权重和推理代码，以赋能社区共同推动这一范式从视觉统一走向通用智能的宏伟愿景。

致谢

本研究完全由作者自费完成。作者在此对开源社区表达诚挚感谢——从预训练模型、代码框架到评测基准，社区的无私共享使得独立研究者也能触及多模态生成的前沿。我们尤其感谢 KiwiEdit、Wan2.2、HuggingFace Diffusers 以及各位匿名审稿人的贡献与启发。当前工作是在有限资源下的概念验证，我们正在为下一阶段更大规模的训练做积极准备。我们热忱欢迎学术界和工业界的同仁基于本开源项目展开合作，共同推进多模态统一生成技术的研究与应用。

References

- [1] Y. Lin 等, “Kiwi-Edit: Versatile Video Editing via Instruction and Reference Guidance,” arXiv preprint arXiv:2603.02175, 2026.
- [2] Q. Bai 等, “Scaling instructionbased video editing with a highquality synthetic dataset,” arXiv:2510.15742, 2025.
- [3] H. He 等, “OpenVE3M: A largescale highquality dataset for instructionguided video editing,” arXiv:2512.07826, 2025.
- [4] Y. Zhang 等, “ReCo: A dataset for instructionbased video editing,” (待发表), 2025.
- [5] Y. Wu 等, “InsViE1M: Effective instructionbased video editing with elaborate dataset construction,” ICCV 2025.
- [6] H. He 等, “OpenVEEdit: Instructionguided video editing with opensource models,” arXiv:2510.07826, 2025.
- [7] T. Wan 等, “Wan: Open and advanced largescale video generative models,” arXiv:2503.20314, 2025.
- [8] W. Kong 等, “HunyuanVideo: A systematic framework for large video generative models,” arXiv:2412.03603, 2024.